Módulo 3

Análisis exploratorio y preprocesamiento de datos

Mercados voluntarios de carbono

Este notebook desarrolla un análisis exploratorio (EDA) sobre un dataset real de mercados voluntarios de carbono.

El dataset ha sido construido a partir de la integración de distintas fuentes (Climate Action Data Trust, Verra, Gold Standard), estructurado en formato Excel y organizado en capas.

El objetivo es preparar los datos para su uso en un pipeline reproducible, identificando problemas estructurales, aplicando técnicas de limpieza y analizando la distribución del mercado.

In [9]:
```
import pandas as pd
import seaborn as sns
import matplotlib.pyplot as plt
import numpy as np
```

Carga del dataset

Se carga la capa de oferta temporal (Supply_TS), que contiene información sobre créditos emitidos por proyecto y año.

Dado que el dataset presenta una estructura no estándar, es necesario ajustar las cabeceras.

In [10]:
```
df = pd.read_excel("BD_Creditos_Forestales_3Capas.xlsx", sheet_name="CAPA2_Suppl

# arreglar cabecera
df.columns = df.iloc[0]
df = df[1:].copy()

# limpiar nombres
df.columns = df.columns.str.strip().str.lower().str.replace(" ", "_")
```

Validación inicial del dataset

Se inspecciona la estructura del dataset para identificar:

- Tipos de variables

- Valores nulos
- Posibles inconsistencias

Este paso permite detectar problemas que pueden afectar al análisis.

In [11]:
```
df.info()
print(df.head())
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 8422 entries, 1 to 8422
Data columns (total 13 columns):
 #   Column                       Non-Null Count  Dtype
---  ------                       --------------  -----
 0   master_id                    8422 non-null   object
 1   registry_id_original         8422 non-null   object
 2   year                         8062 non-null   object
 3   year_type                    8422 non-null   object
 4   credits_issued_tco2          6237 non-null   object
 5   credits_retired_tco2         3343 non-null   object
 6   credits_available_tco2       4820 non-null   object
 7   credits_issued_issuance_year 2752 non-null   object
 8   credits_issued_cumulative    6237 non-null   object
 9   credits_retired_cumulative   3343 non-null   object
 10  buffer_contribution_tco2     2096 non-null   object
 11  source_reliability           8422 non-null   object
 12  data_source                  8422 non-null   object
dtypes: object(13)
memory usage: 855.5+ KB
0  master_id registry_id_original  year year_type credits_issued_tco2  \
1  FOR-00004              ACR1006  2022   VINTAGE               4176
2  FOR-00004              ACR1006  2023   VINTAGE              18362
3  FOR-00004              ACR1006  2024   VINTAGE               4578
4  FOR-00004              ACR1006  2025   VINTAGE                NaN
5  FOR-00018               ACR105  2011   VINTAGE            2572210

0 credits_retired_tco2 credits_available_tco2 credits_issued_issuance_year  \
1                  NaN                   4176                          NaN
2                  NaN                  18362                          NaN
3                  NaN                   4578                          NaN
4                  NaN                    NaN                        27116
5                  NaN                    NaN                          NaN

0 credits_issued_cumulative credits_retired_cumulative  \
1                      4176                        NaN
2                     22538                        NaN
3                     27116                        NaN
4                       NaN                        NaN
5                   2572210                        NaN

0 buffer_contribution_tco2 source_reliability data_source
1                      NaN               HIGH    BERKELEY
2                      NaN               HIGH    BERKELEY
3                      NaN               HIGH    BERKELEY
4                      NaN               HIGH    BERKELEY
5                      NaN               HIGH    BERKELEY
```

In [12]:
```
sns.heatmap(df.isnull(), cbar=False)
plt.title("Valores nulos en el dataset")
plt.show()
```

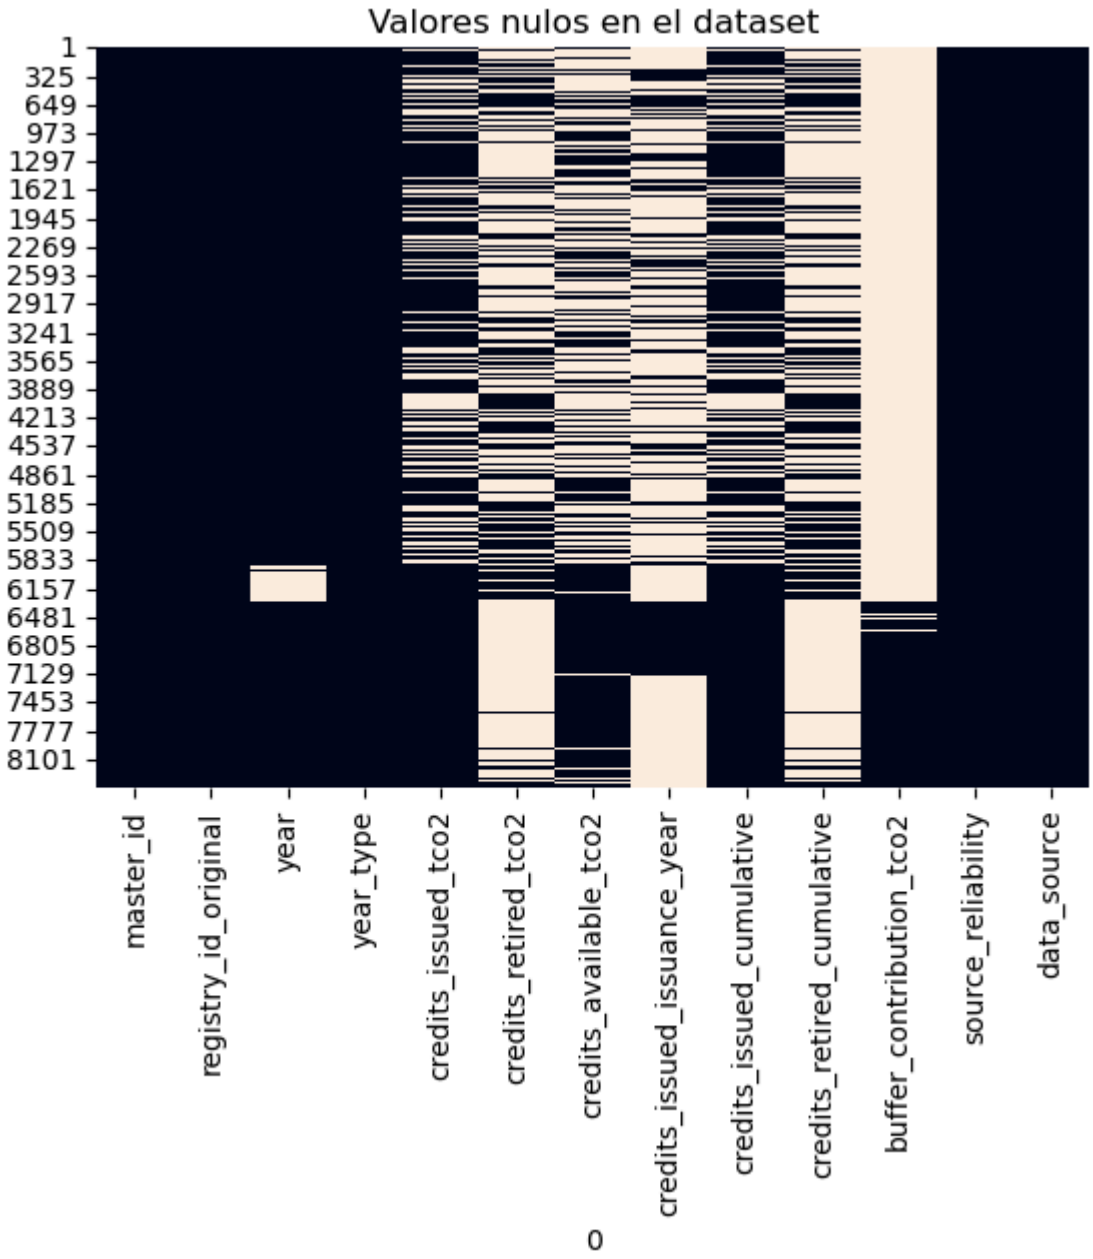

Se observa la presencia de valores nulos y posibles inconsistencias en los tipos de variables, lo que requiere un proceso de limpieza previo.

Preprocesamiento y limpieza

Se aplican varias técnicas:

- Conversión de tipos de datos
- Eliminación de valores nulos
- Preparación del dataset para análisis

Estas operaciones permiten obtener una estructura consistente.

In [13]:
```
df["year"] = pd.to_numeric(df["year"], errors="coerce")
df["credits_issued_tco2"] = pd.to_numeric(df["credits_issued_tco2"], errors="coe
```

```
df = df.dropna(subset=["year", "credits_issued_tco2"])
df = df.reset_index(drop=True)
```

Agregación temporal

Se agregan los créditos emitidos por año para analizar la evolución del mercado.

In [14]:
```
df_year = df.groupby("year")["credits_issued_tco2"].sum().reset_index()
```

Distribución de créditos emitidos

Se analiza la distribución de la variable principal.

La distribución muestra una fuerte asimetría, indicando que la mayoría de proyectos generan pocos créditos, mientras que unos pocos concentran grandes volúmenes.

In [15]:
```
sns.histplot(df["credits_issued_tco2"], bins=50)
plt.title("Distribución de créditos emitidos")
plt.show()
```

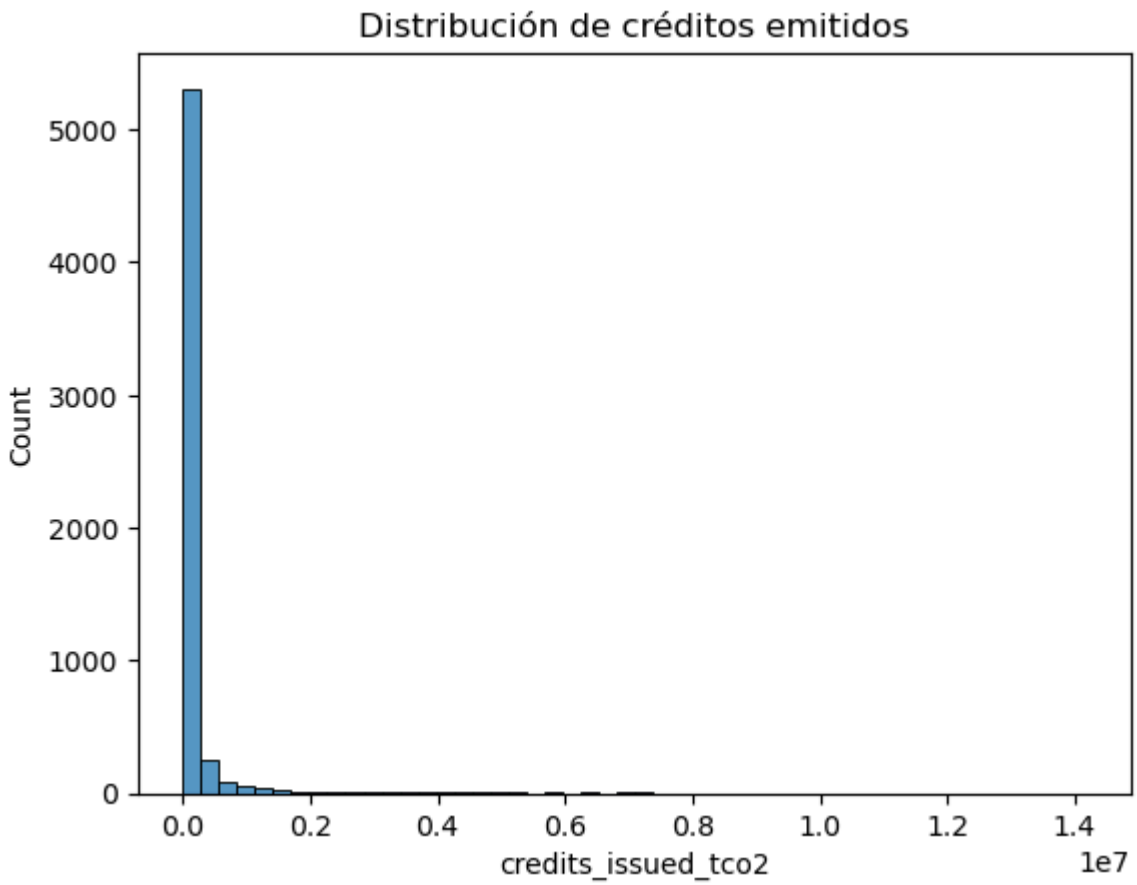

Evolución temporal del mercado

Se representa la evolución de los créditos emitidos a lo largo del tiempo.

Se observa una tendencia creciente, aunque con alta variabilidad.

In [16]:
```
sns.lineplot(data=df_year, x="year", y="credits_issued_tco2")
plt.title("Evolución de créditos emitidos")
plt.show()
```

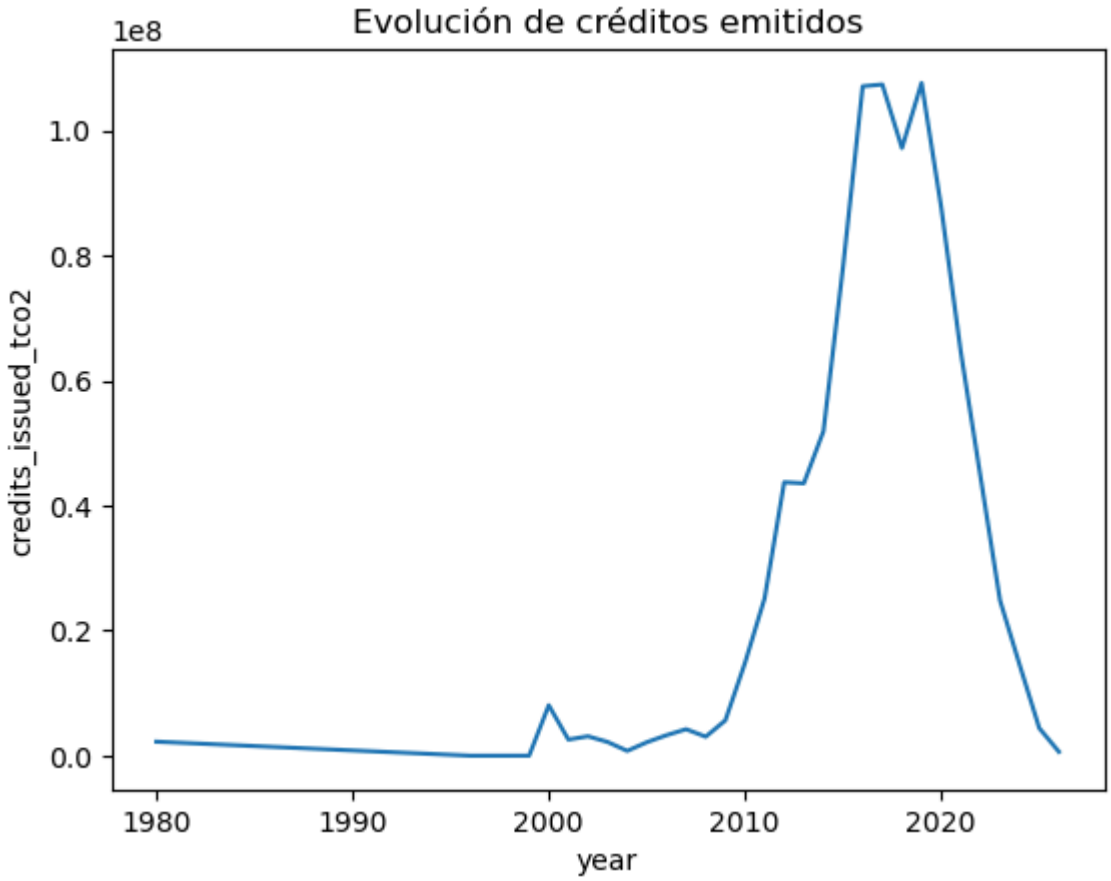

Transformación logarítmica

Se aplica una transformación logarítmica para reducir la asimetría y mejorar el análisis.

In [17]:
```
df["log_credits"] = np.log1p(df["credits_issued_tco2"])

sns.histplot(df["log_credits"], bins=50)
plt.title("Distribución logarítmica")
plt.show()
```

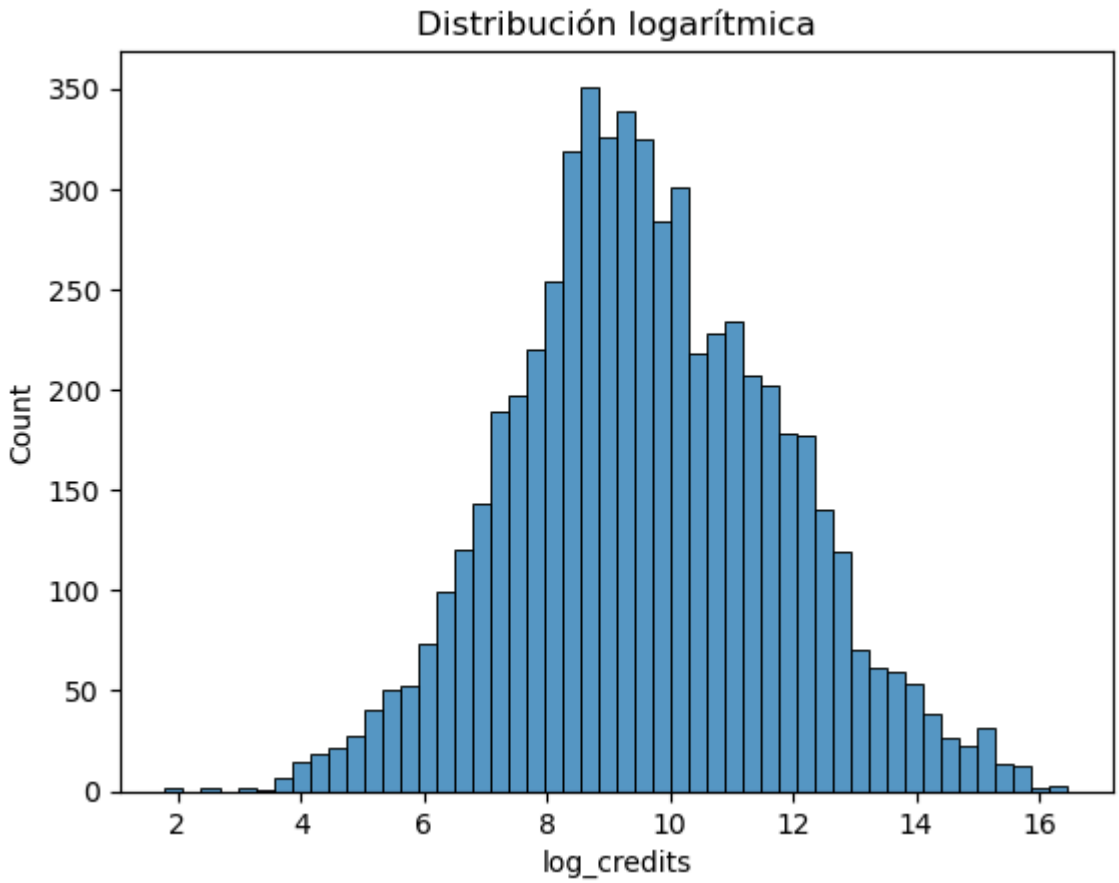

Concentración por proyectos

Se identifican los proyectos con mayor volumen de créditos.

Se observa una alta concentración del mercado.

In [18]:
```
top_projects = df.groupby("master_id")["credits_issued_tco2"].sum().sort_values(

sns.barplot(x=top_projects.values, y=top_projects.index)
plt.title("Top proyectos")
plt.show()
```

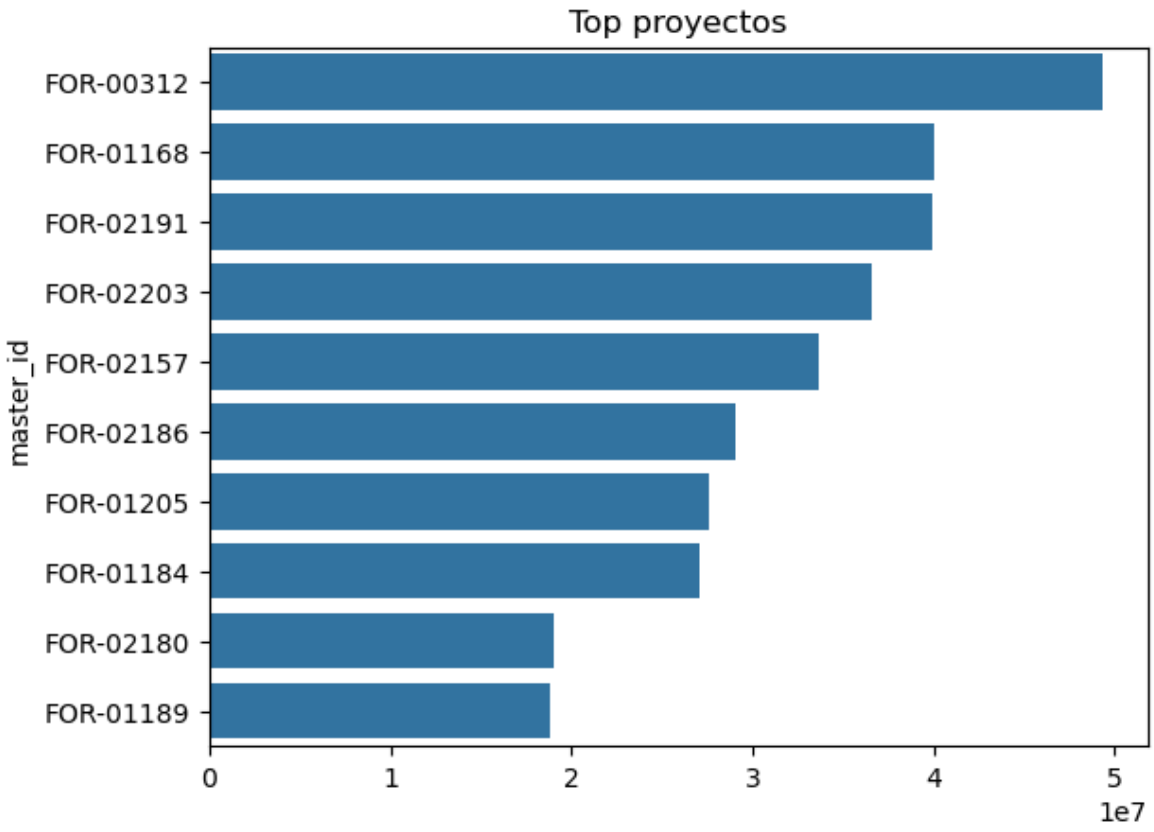

Variables derivadas

Se crean nuevas variables para enriquecer el análisis.

In [19]:
```
df["growth_rate"] = df.groupby("master_id")["credits_issued_tco2"].pct_change()
df["project_size"] = pd.qcut(df["credits_issued_tco2"], q=3, labels=["small", "m
```

Análisis de concentración

Se analiza la concentración acumulada del mercado.

In [20]:
```
df_total = df.groupby("master_id")["credits_issued_tco2"].sum().sort_values(asce
df_total_cum = df_total.cumsum() / df_total.sum()

plt.plot(df_total_cum.values)
plt.title("Concentración acumulada del mercado")
plt.show()
```

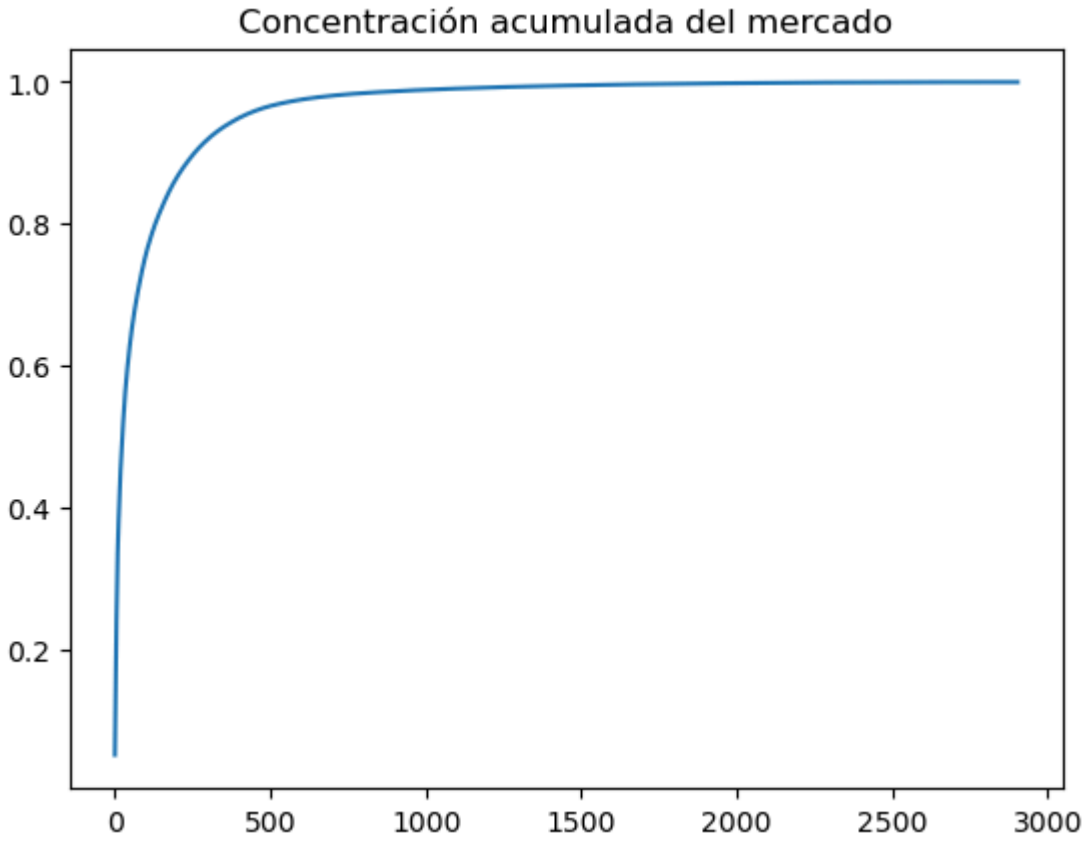

Síntesis del análisis

El análisis exploratorio ha permitido identificar:

- Una distribución altamente sesgada
- Una fuerte concentración del mercado
- Una tendencia creciente en el tiempo

Tras el preprocesamiento, el dataset presenta una estructura consistente y adecuada para análisis avanzados.

Este trabajo prepara los datos para su uso en modelización y en un pipeline reproducible de análisis de mercados voluntarios de carbono.